

Mémoire de fin d'étude pour l'obtention de la Licence Sciences Mathématiques et Informatique Option : Base de données

Sujet :

SCRAPING ET ANALYSE DE TEXTES EN DIALECT MAROCAIN

Encadré par :

Pr BENLAHMAR EL HABIB

Réalisé par :

EL MESKINI Ranja

EL AOUDI Oussama

Soutenu le 17/ 06/ 2022 , devant le jury :

BENLAHMAR EL HABIB

Président

ELFILALI SANNA

Examinateur

ZAHOUR OMAR

Examinateur

QUAHABI SARA

Examinateur

Remerciement :

Arrivée au terme de notre formation, nous tenons à remercier en premier temps toute l'équipe pédagogique de la faculté des sciences Ben Msik pour avoir assuré notre formation.

Nous remercions également monsieur ELHABIB BENLAHMAR qui n'a pas cessé de nous encourager pendant la durée du projet, ainsi pour sa générosité en matière de formation et d'encadrement qu'il nous a apporté lors des différents suivis et la confiance qu'il nous a témoigné.

Nous remerciements s'adressent aussi à l'ensemble de membres de jury PR ZAHOUR OMAR et PR ELFILALI SANNA qui nous ont fait l'honneur de bien vouloir étudier notre travail avec attention.

Dédicaces :

Nous dédions ce modeste travail et notre profonde gratitude et amour :

À nos chers parents :

Aucune dédicace suffira à exprimer notre grand amour, immense respect et reconnaissance envers les personnes qui ont tous sacrifier afin de nous offrir une meilleure éducation et vie, nous ne pourrions jamais oublier leurs tendresse et amour.

À ma grand-mère :

La femme qui m'a comblé d'amour et d'affection, qui a œuvré toujours pour ma réussite.

À nos frères et sœur :

Qui n'ont pas cessé de nous conseiller, encourager et soutenir tout au long de ce parcours.

À nos amis :

Notre seconde famille pour leur appuis, soutien moral et leurs aides durant toute cette année.

Résumé :

Le web scraping est une technique permettant l'extraction de données d'un site web via un programme ou un logiciel automatique. L'objectif est donc d'extraire les données d'une façon structurée afin de le pouvoir les réutiliser et les analyser en classifiant les textes extrait soit par sentiments, par sujet ou par intentions.

Dans ce travail, nous appliquons le web scraping sur le site web JUMIA afin d'extraire l'ensemble de commentaires sur des articles de différentes catégories et ensuite les analyser pour savoir la polarité d'avis des clients du site web (positive, négative, ou neutre).

Nous présentons tout au long de ce rapport, les étapes suivies ainsi que les outils et les techniques utilisées afin de réaliser ce projet.

Abstract :

Web scraping is a technique that allows the extraction of data from a website via a program or an automatic software. The objective is to extract the data in a structured way in order to be able to reuse and analyze them by classifying the extracted texts either by feelings, by subject or by intentions.

In this project, we apply web scraping on the JUMIA website in order to extract the set of comments on articles of different categories and then analyze them to know the polarity of customers opinions on the website (positive, negative, or neutral).

Throughout this report, we present the steps followed as well as the tools and techniques used to used in order to realize this project.

Table des matières

Remerciement :	3
Dédicaces :	4
Résumé :	5
Abstract :	6
Table des matières	7
Liste des figures :	8
Introduction générale :	9
Chapitre 1 : contexte général du projet.....	10
Introduction :	10
1.1 Problématique :.....	10
1.2 Objectifs :.....	11
1.3 Travail connexe :	11
Conclusion :	12
Chapitre 2 : analyse et conception.....	12
Introduction :	12
2.1 Le site web :.....	12
2.2 Outils de développements :.....	13
Conclusion :	18
Chapitre 3 : Réalisation et résultat.....	18
Introduction :	18
3.1 Choix de l'URL de la page :.....	18
3.2 Inspecter la page web :	20
3.3 Classe des commentaires :	21
3.4 Le code :	23
3.5 La partie d'analyse :	25
3.5 Résultat :.....	25
Conclusion :	28
Conclusion :	28

Liste des figures :

Figure 1 - un article sans commentaire.....	10
Figure 2 - un article avec des commentaires.....	11
Figure 3 - site web JUMIA.....	13
Figure 4 - site web JUMIA.....	13
Figure 5 - logo python.....	14
Figure 6 - natural language processing.....	14
Figure 7 - logo visual studio.....	15
Figure 8 - logo selenium	15
Figure 9 - selenium WebDriver.....	17
Figure 10 - logo pandas.....	17
Figure 11 - catégorie supermarché	19
Figure 12 - catégorie vêtements et chaussures.....	19
Figure 13 - catégorie téléphone et tablette	20
Figure 14 - page web inspecté.....	21
Figure 15 - section des commentaires	21
Figure 16 - reste des commentaires	22
Figure 17 - contenu de commentaire	23
Figure 18 - importation des librairies	24
Figure 19 - le code	24
Figure 20 - code (suite)	25
Figure 21 - résultat 1	26
Figure 22 - résultat 2	26
Figure 23 - résultat 3	27
Figure 24 - résultat analyse	27

Introduction générale :

Le web scraping désigne le processus d'extraction de données, c'est une méthode automatique qui permet d'obtenir de grande quantité de données à partir de sites web. Ces données sont des données non structurées au format HTML qui seront ensuite transformé ou converties en format plus utile pour l'utilisateur dans un tableur ou une base de données dans le but de pouvoir être ré-utilisées par la suite dans plusieurs applications.

Le text Mining ou analyse de texte est une pratique qui permet aux machines de comprendre et de traiter le langage humain automatiquement en classifiant les textes par sentiment, par sujet ou par intention. L'analyse de texte est souvent utilisée par des entreprises sur leurs sites web pour savoir le feedback des clients et leur besoin.

Dans ce projet, nous allons extraire un ensemble de commentaires d'un site web et les structurer d'une manière plus simple et efficaces pour pouvoir ensuite les analyser et les classifier afin de savoir s'ils sont positifs, négatifs ou neutres.

Ce projet est proposé par le professeurs Mr BENLAHMAR EL HABIB pour faire l'objet de notre projet de fin d'étude. Ce projet nous permettons d'avoir un sujet à traiter sous la lumière des connaissances acquises tout au long de nos études.

Ce rapport présente les différentes étapes de réalisation de notre projet. Il comporte deux parties dont la composition est comme suit : La première partie concerne le scraping du site web JUMIA afin de collecter le maximum possible de commentaires sur des produits de différentes catégorie. La deuxième partie est dédié à l'analyse de ces commentaires en leurs classification par sentiments. Nous conclurons par la suite par un bilan personnel et les problèmes rencontrer.

Chapitre 1 : contexte général du projet

Introduction :

Dans ce chapitre, nous passerons en revue les connaissances de base sur notre projet. Nous présenterons aussi une problématique.

1.1 Problématique :

Pour extraire les données ou bien précisément les commentaires d'un site web il faut en premier temps savoir leur emplacement et parfois il existe des articles sans aucun commentaires du coup la collection des informations pose quand même un problème.

En outre, pour avoir une vraie analyse des commentaires et avoir les feedbacks valables, il faut travailler sur un nombre massif de commentaires.

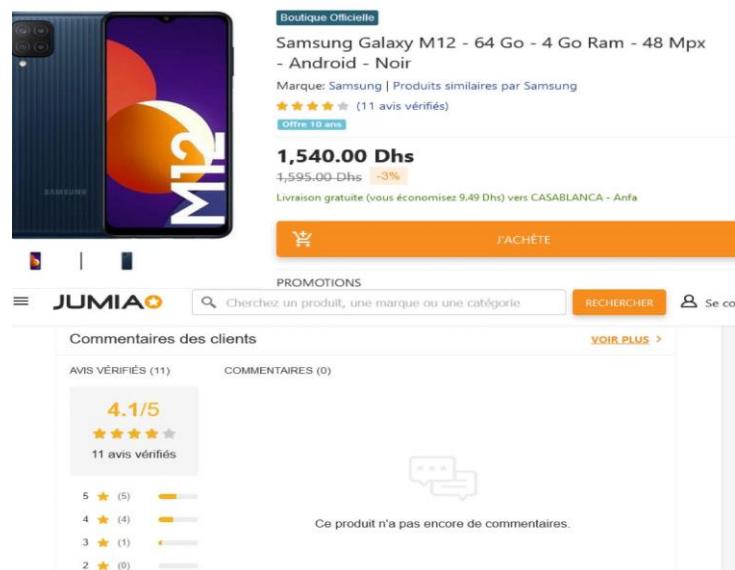


Figure 1 - un article sans commentaire

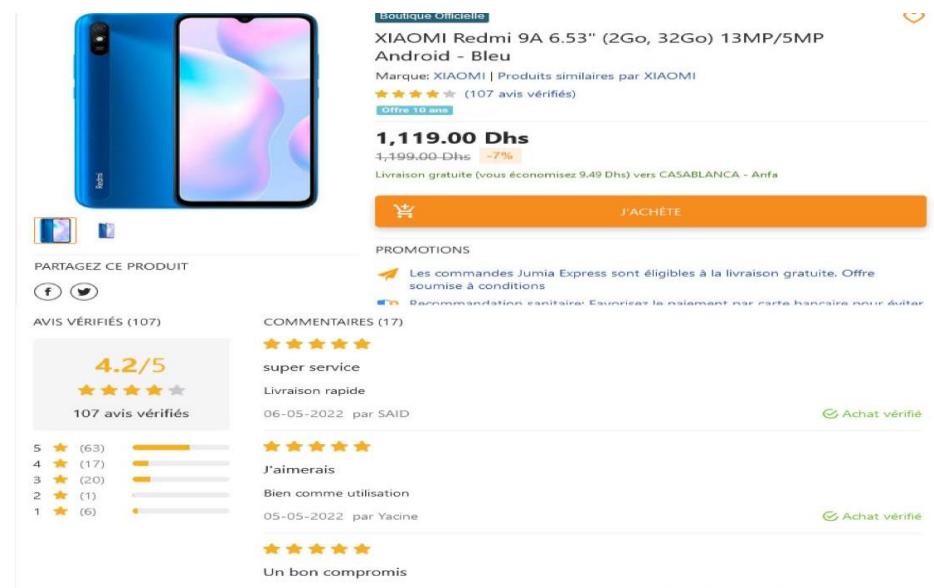


Figure 2 - un article avec des commentaires

1.2 Objectifs :

Afin de réussir notre projet, nous nous sommes fixées des objectifs à atteindre à la fin de ce projet :

- Collecter le maximum de commentaires d'un site web
- Classifier ces commentaires en 3 catégories : positive, négative ou neutre.

1.3 Travail connexe :

Le web scraping est utilisé pour plusieurs tâches. Il permet par exemple, de récolter rapidement des données de contact ou des informations spécifiques.

Dans le domaine professionnel, le web scraping est souvent utilisé pour accéder à des avantages par rapport à des concurrents. Le scraping de données permet à une société de consulter tous les produits d'un concurrent et les comparer avec ses propres produits. Il apporte également une valeur ajoutée pour les données financières : les informations sont lues depuis un site Internet externe, transférées dans un tableau et peuvent ensuite être analysées et traitées.

Google constitue un bon exemple de Web scraping. Le moteur de recherche utilise cette technologie afin d'afficher des informations météorologiques ou des comparatifs de prix pour des hôtels et des vols. Parmi les comparateurs de prix, nombreux sont ceux à également utiliser le Web scraping afin d'afficher des informations de nombreux sites Internet et prestataires.

Conclusion :

Ce chapitre a permis de situer le contexte général du projet et d'expliquer la vision stratégique à laquelle il adhère. A ce niveau, il y a lieu de s'interroger sur les besoins que ce projet doit rencontrer, c'est ce que détaillera le prochain chapitre.

Chapitre 2 : analyse et conception

Introduction :

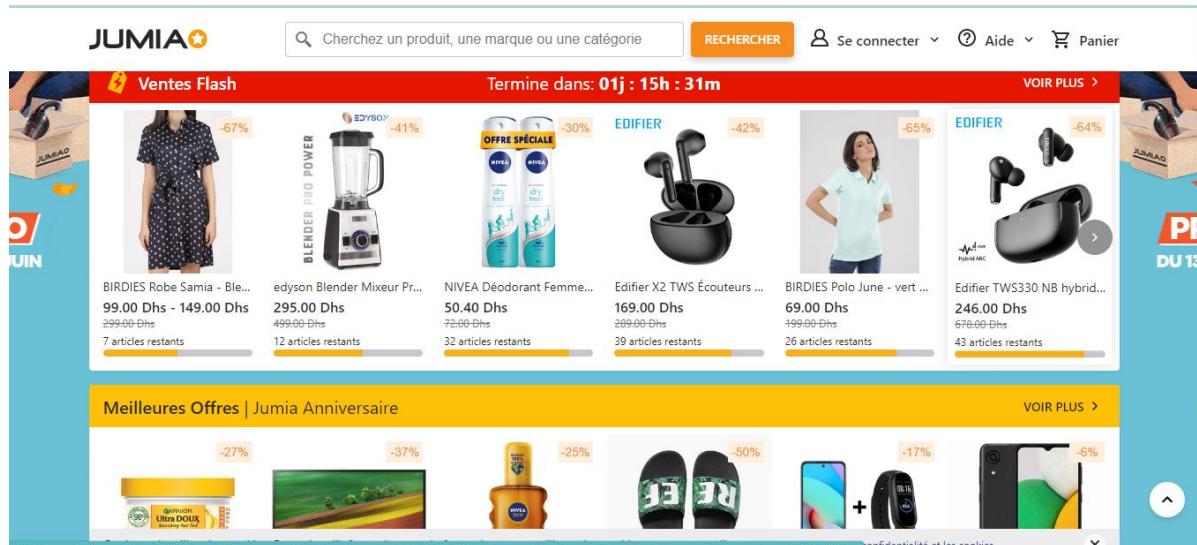
Dans ce chapitre, nous allons présenter toutes les méthodes et techniques utilisées pour obtenir les meilleurs résultats possibles.

2.1 Le site web :

Durant ce projet nous avons travaillé sur le site web JUMIA.

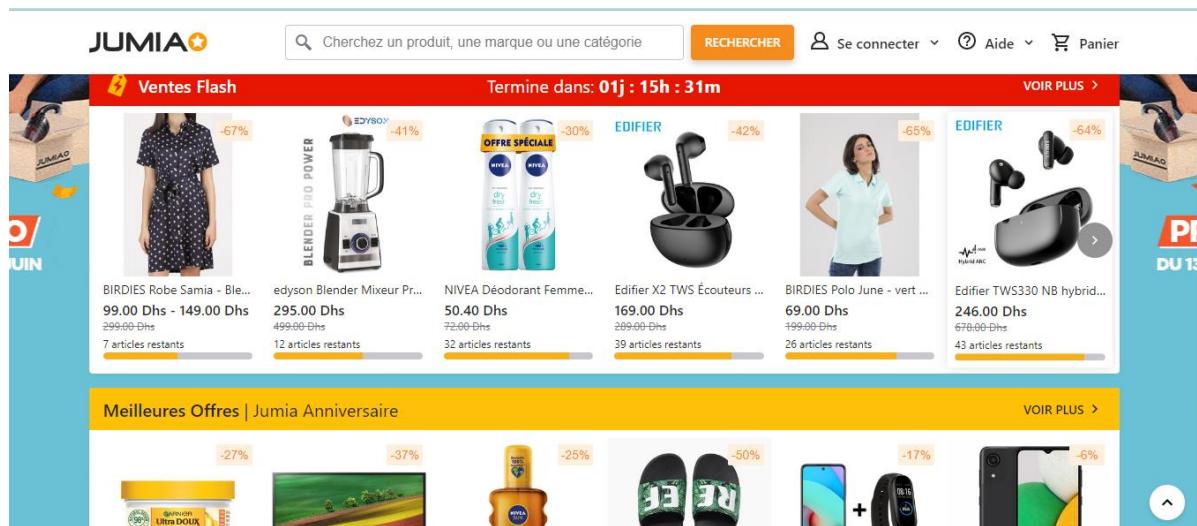
JUMIA est un site d'achats en ligne fondé en 2012 et ayant son siège à Casablanca, il fait parti du top 10 site web au Maroc et il est incontestablement la première destination du shopping en ligne. Le site web contient +300 000 produits de différentes catégories, et 8,5 millions du visite mensuelles. Nous avons posé notre choix sur le site web JUMIA parce qu'il

propose une grande quantité de commentaires et de données pour scraper et analyser par la suite.



The screenshot shows a promotional banner for 'Ventes Flash' (Flash Sales) with a timer counting down to 01j : 15h : 31m. It features six products: a dress (Birdies Robe Samia), a blender (edison Blender Mixeur Pro Power), two bottles of Nivea Deodorant, Edifier X2 TWS Earbuds, a polo shirt (Birdies Polo June), and another pair of Edifier TWS earbuds. Each product has a discount percentage (e.g., -67%, -41%, -30%, -42%, -65%, -64%) and a count of remaining items (e.g., 7 articles restants, 12 articles restants, 32 articles restants, 39 articles restants, 26 articles restants, 43 articles restants).

Figure 3 - site web JUMIA



The screenshot shows a promotional banner for 'Meilleures Offres | Jumia Anniversaire' (Best Offers | Jumia Anniversary). It features several products: a soap bar (Bionion Ultra DOUX), a lotion bottle (Nivea), a pair of slippers (REEFEE), a smartphone, and a fitness tracker. Each item has a discount percentage (e.g., -27%, -37%, -25%, -50%, -17%) and a small image of the product.

Figure 4 - site web JUMIA

2.2 Outils de développements :

- Python :



Figure 5 - logo python

Python est un langage de programmation puissant et facile à apprendre. Il dispose de structures de données de haut niveau et permet une approche simple mais efficace de la programmation orientée objet. Parce que sa syntaxe est élégante, que son typage est dynamique et qu'il est interprété, Python est un langage idéal pour l'écriture de scripts et le développement rapide d'applications dans de nombreux domaines et sur la plupart des plateformes. Ainsi, Python contient plusieurs bibliothèques du machine Learning, ce qu'il le rend plus adapté à notre projet.

- Natural Language Processing (NLP) :

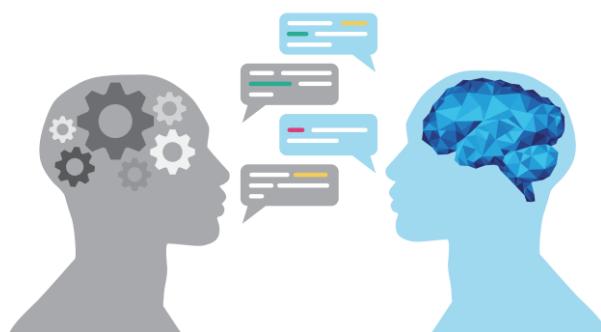


Figure 6 - natural language processing

Le NLP pour Natural Language Processing ou Traitement du Langage Naturel est une discipline qui porte essentiellement sur la compréhension, la manipulation et la génération du langage naturel par les machines. Ainsi, le NLP est réellement à l'interface entre la science informatique et la linguistique. Il porte donc sur la capacité de la machine à interagir directement avec l'humain.

- Visual studio :

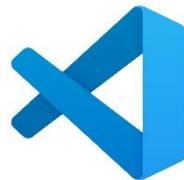


Figure 7 - logo visual studio

Microsoft Visual Studio est une suite de logiciels de développement pour Windows conçu par Microsoft.

- Selenium :



Figure 8 - logo selenium

Selenium est un Framework développé en java, qui offre des passerelles pour s'exécuter avec différents langages comme Python et PHP. Il s'agit d'un outil puissant pour contrôler les navigateurs web grâce à des programmes et effectuer l'automatisation du navigateur. Il prend en compte tous les navigateurs, tous les principaux systèmes d'exploitation et ses scripts sont écrits dans différents langages comme Python, java, C# ...

Selenium permet une automatisation efficace des tests de l'interface graphique des applications Web. Il est composé principalement de 4 composants à savoir : Selenium IDE, Selenium RC, Selenium Webdriver et Selenium GRID.

Avantages :

- Est un framework open source et portable.
 - Peut être utilisé avec de nombreux navigateurs et plateformes différents.
 - Peut explorer un site Web à l'aide d'un navigateur spécifique : bien que de nombreux logiciels de scraping de sites Web utilise un véritable navigateur Web pour l'extraction de données, dans la plupart des cas, le navigateur qu'ils utilisent est WebBrowser Control, c'est-à-dire Internet Explorer. Selenuim, cependant, fonctionne non seulement avec Internet Explorer, mais aussi avec une variété de navigateurs tels que Google Chrome, Firefox....
-
- Selenium WebDriver :



Figure 9 - selenium WebDriver

Selenium Webdriver accepte les commandes (envoyées en Selenese, ou via une API cliente) et les envoient à un navigateur. Ceci est implémenté via un pilote de navigateur spécifique au navigateur, qui envoie des commandes à un navigateur et récupère les résultats. Il n'a pas besoin d'un serveur spécial pour exécuter les tests.

- Pandas :



Figure 10 - logo pandas

Pandas est une bibliothèque open source conçue principalement pour travailler avec des données relationnelles ou étiquetées à la fois facilement et intuitivement. Il fournit diverses structures de données et opérations pour

manipuler des données numériques et des séries chronologiques.

Cette bibliothèque est construite sur le dessus de la bibliothèque NumPy.

Pandas est rapide et offre des performances et une productivité élevée pour les utilisateurs.

Conclusion :

Ce chapitre, nous a permis d'analyser et étudier l'ensemble de techniques et outils utilisées lors de la réalisation de notre projet.

Chapitre 3 : Réalisation et résultat

Introduction :

Nous présentons dans ce chapitre les détails de la mise en œuvre, ensuite les résultats de chaque étape du projet.

3.1 Choix de l'URL de la page :

La première étape du web scraping est de choisir l'URL. Dans notre cas nous avons choisi 3 URL de vente de 3 catégories de produits (qui contiennent le plus de commentaires possibles) :

- Catégorie supermarché :

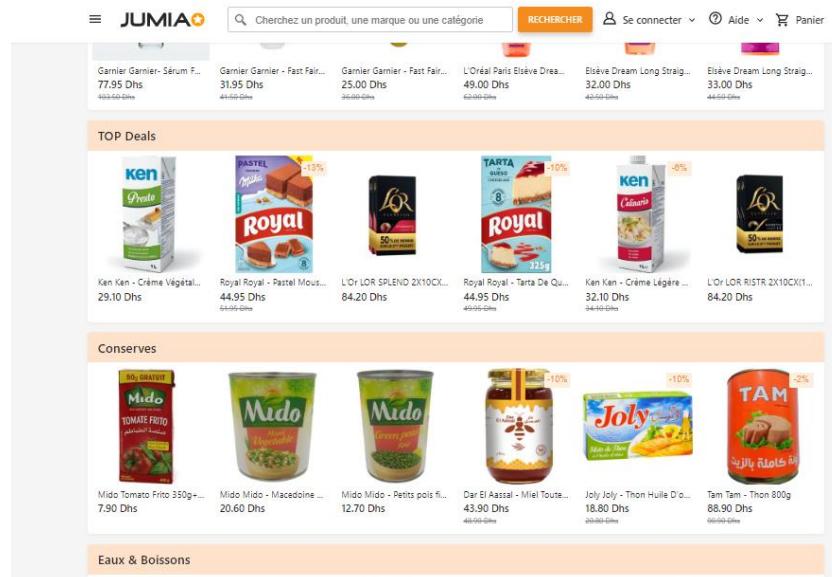


Figure 11 - catégorie supermarché

- Catégorie vêtements et chaussures :

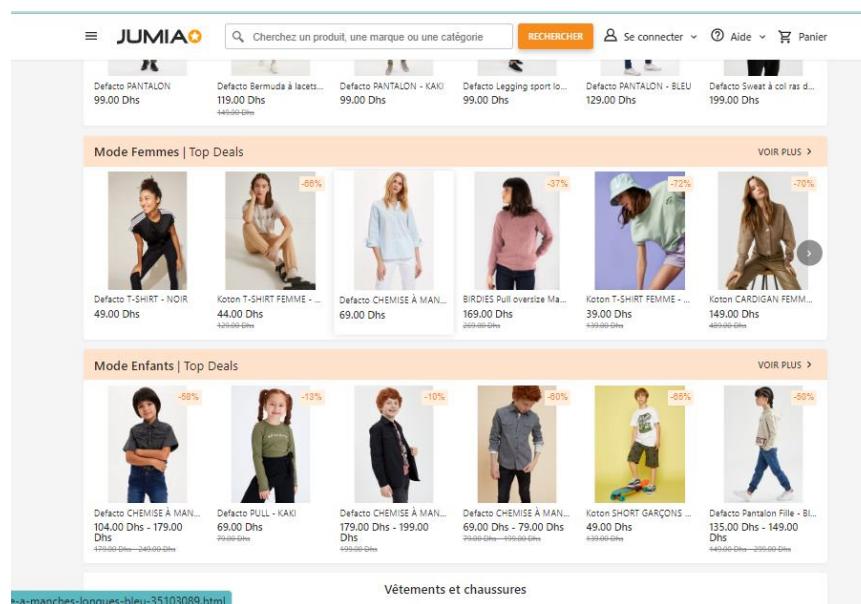


Figure 12 - catégorie vêtements et chaussures

- Catégorie téléphone et tablette :

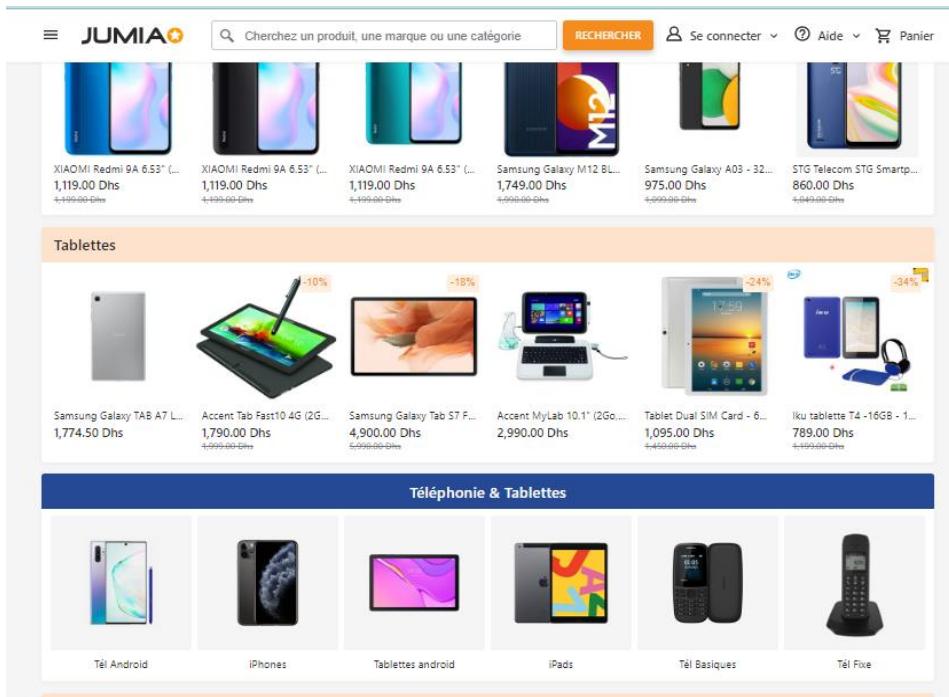


Figure 13 - catégorie téléphone et tablette

3.2 Inspecter la page web :

La deuxième étape du processus consiste à inspecter la page web. Généralement les données sont imbriquées dans des structures imbriquées qu'on appelle tags. Ce qui consiste à inspecter les pages et chercher l'emplacement des données que nous voulons extraire dans notre cas les commentaires des produits.

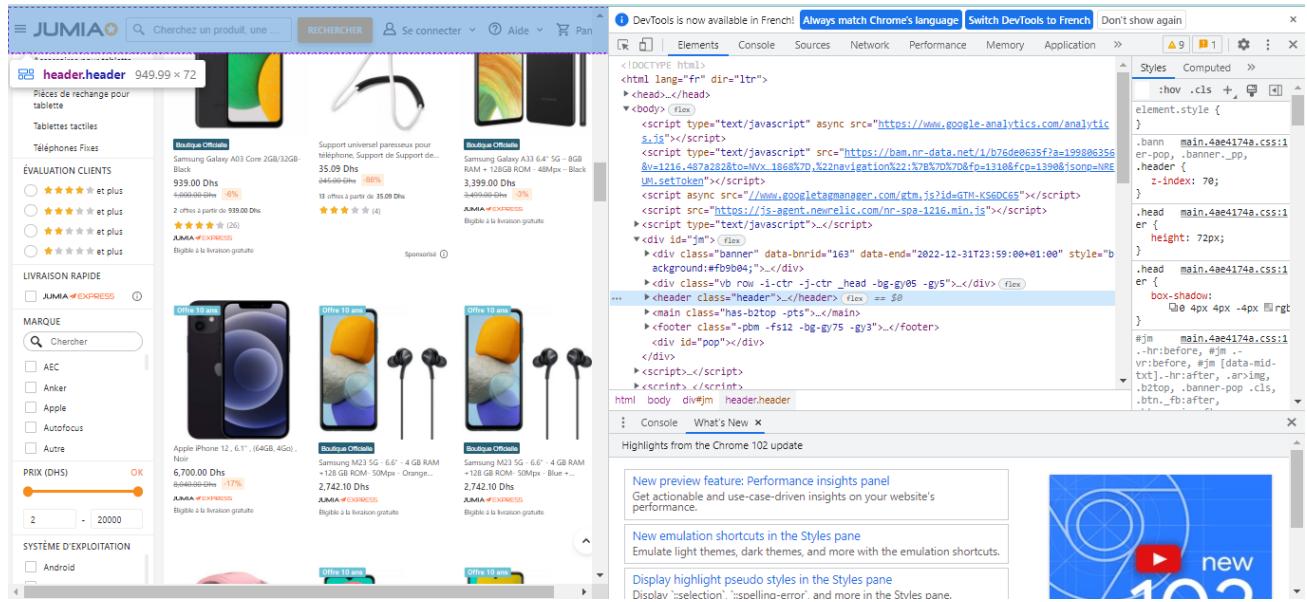


Figure 14 - page web inspecté

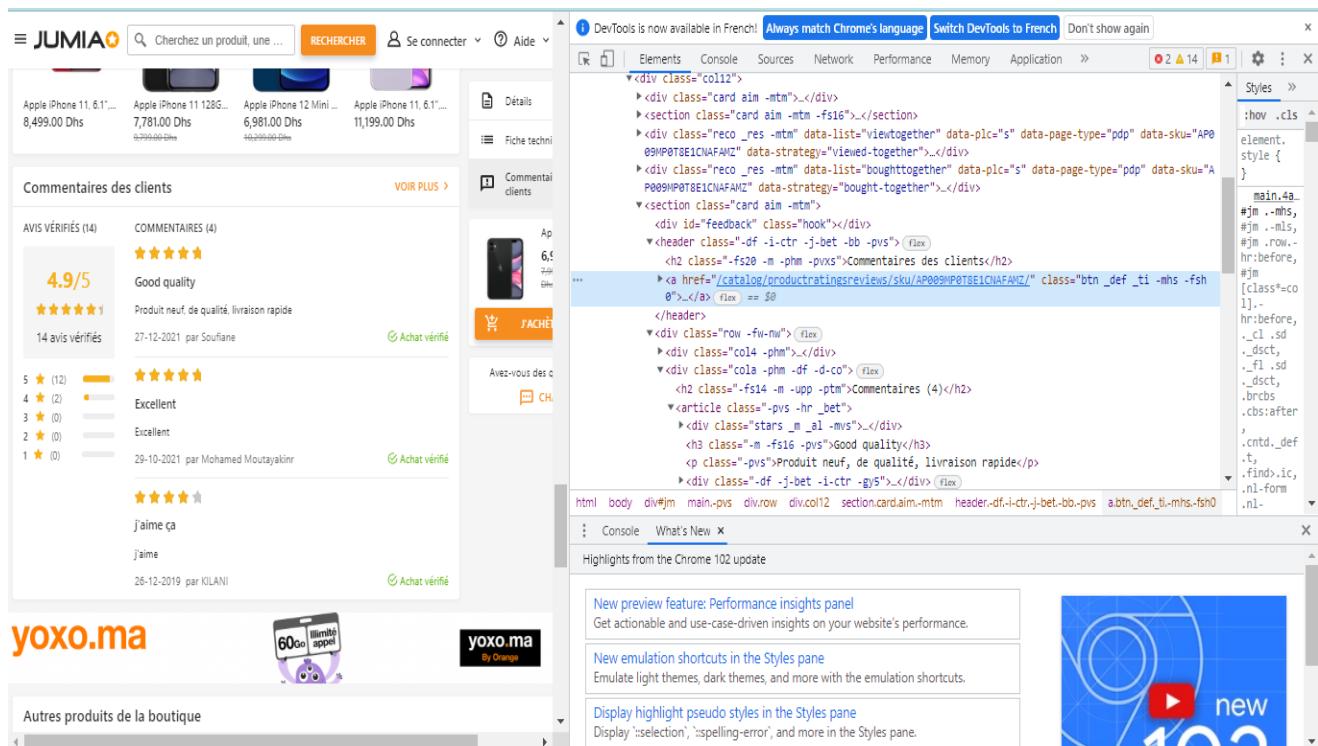
3.3 Classe des commentaires :

Nous cherchons la classe des commentaires des produits.

Figure 15 - section des commentaires

Nous pouvons constater que la classe de la division qui contient la section les commentaires des produits est : `<div class= "cola -phm -df -d-co">`.

Cependant cette classe ne donne que les quatre premiers commentaires. Pour avoir le reste il faut récupérer la classe qui contient l'URL des restes du commentaires.



The screenshot shows a Jumia product page for an iPhone 11. The main content includes product details like price and availability, followed by a section titled 'Commentaires des clients'. This section shows a summary of reviews (14 avis vérifiés) and a list of four reviews. The DevTools panel on the right highlights the HTML structure of this section, specifically the class `cola -phm -df -d-co`. The URL for the full comments section is visible in the DevTools sidebar. The bottom of the screenshot shows the Chrome 102 update highlights.

Figure 16 - reste des commentaires

Alors la classe qui contient l'ensemble des commentaires est : `<a href="/catalog/productatingsreviews/sku/AP009MP0T8E1CNAFAMZ/" class= "btn _def _ti -mhs -fsh0".`

Ensuite, nous inspectons la classe du paragraphe qui contient le contenu de commentaire.

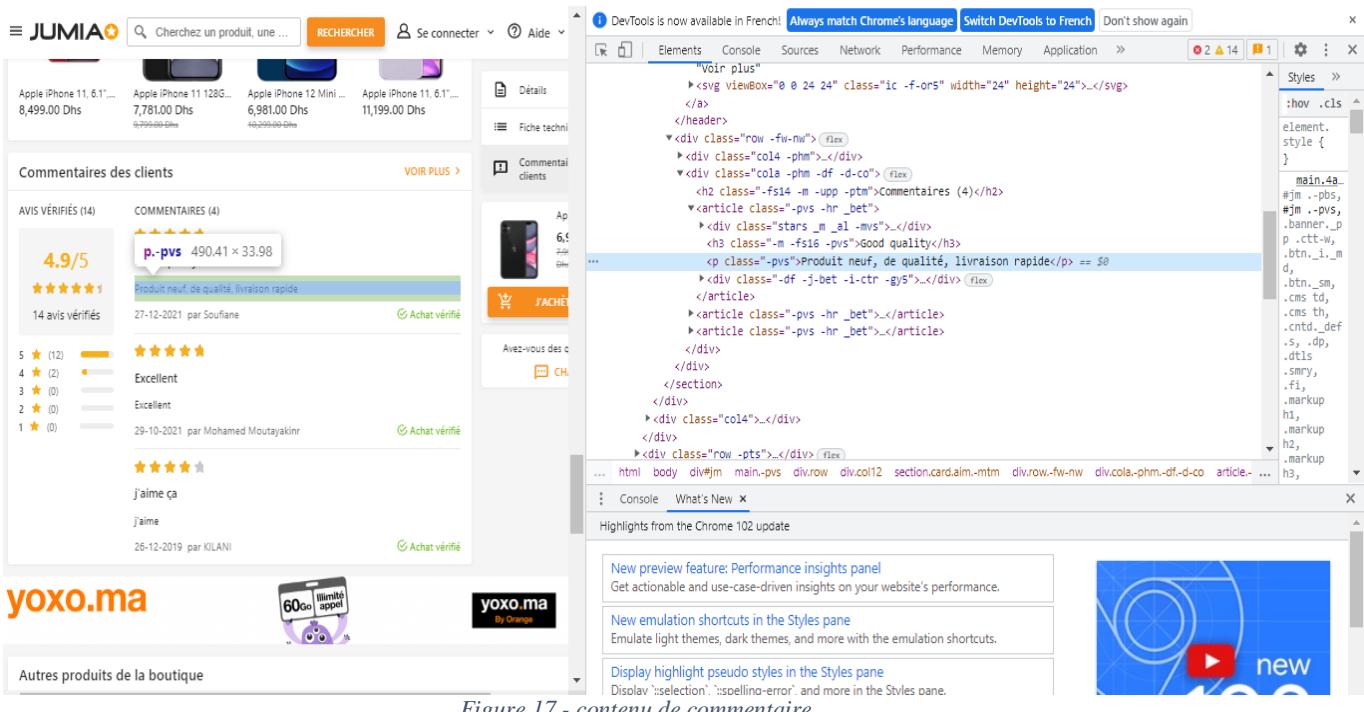


Figure 17 - contenu de commentaire

Nous remarquons que le contenu des commentaires se trouve dans la classe :

<p class="-pvs">.

3.4 Le code :

Pour la partie code, nous commençons par l'importation des librairies : pandas, selenium et selenium WebDriver

```

1  from selenium import webdriver
2  from selenium.webdriver.common.by import By
3  from selenium.webdriver.support.ui import WebDriverWait
4  from selenium.webdriver.support import expected_conditions as EC
5  import undetected_chromedriver as uc
6  import time
7  import sys
8  import pandas as pd
9

```

Figure 18 - importation des librairies

Nous avons utilisé le driver chrome.

```

9
10 def scrap(url):
11     options = uc.ChromeOptions()
12
13     options.add_argument("--headless")
14
15     driver = uc.Chrome(options=options)
16     wait = WebDriverWait(driver, 5)
17     commentaires_list = []
18     driver.get("https://www.jumia.ma/telephone-tablette/")
19
20     #content = driver.find_element(By.CLASS_NAME, 'prd_box_hvr')
21
22     content = driver.find_elements(By.CSS_SELECTOR, '.itm.col')
23     urls = []
24     for element in content:
25         urls.append(element.find_element(By.CSS_SELECTOR, '.core').get_attribute('href'))
26
27     for url in urls:
28         driver.get(url)
29         try:
30             content = driver.find_elements(By.CSS_SELECTOR, 'header.-df.-i-ctr.-j-bet.-bb.-pvs')
31             link = driver.find_element(By.CSS_SELECTOR, 'a.btn.-def.-ti.-mhs.-fsh0')
32             driver.get(link.get_attribute('href'))
33
34             comments_section = driver.find_elements(By.CSS_SELECTOR, '.cola.-phm.-df.-d-co')
35             try:
36                 comments = comments_section[0].find_elements(By.CSS_SELECTOR, 'p.-pvs')
37             except IndexError:
38                 continue
39             for comm in comments:
40                 commentaires_list.append(comm.text)
41         except :

```

Figure 19 - le code

Ensuite, après l'importations des librairies, nous avons commencé par créer l'instance du WebDriver chrome. Par la suite la méthode driver.get navigue la page web donnée par l'URL.

Le WebDriver offre plusieurs manières pour trouver les éléments, parmi ces manières la méthode find_element et By.CSS_SELECTOR comme premier paramètre, et en seconde paramètre les classes des données qu'on voulait récupérer et inspecté dans la première étape.

```

38         continue
39     for comm in comments:
40         commentaires_list.append(comm.text)
41     except :
42         continue
43
44     data = pd.DataFrame(commentaires_list,columns=['Commentaire'])
45     return data
46
47 if __name__ == '__main__':
48     sys.stdin.reconfigure(encoding='utf-8')
49     sys.stdout.reconfigure(encoding='utf-8')
50
51
52 url = "https://www.jumia.ma/telephone-tablette/"
53
54 data = scrap(url)
55 data.to_csv('data.csv',index = False)

```

Figure 20 - code (suite)

A l'aide de la librairie Pandas, on stocke les données extraites dans un fichier csv.

3.5 La partie d'analyse :

Dans cette partie, nous travaillons sur la classification des données récupérés, dans notre cas les commentaires des clients sur l'ensemble des produits, dans le but de savoir s'ils sont positifs, négatifs ou neutres.

3.5 Résultat :

Nous exécutons le code et observons que l'ensemble de commentaires serons stocké de la façon suivante :

data.csv

```

1 Commentaire
2 Économisez et Savourez la Coca-Cola
3 نحب كوكا كولا مashi ببىسى ببىسى لا
4 zwina khasha hitabrad hhhh
5 Comme la description 8 pièces
6 Zwin zwin
7 J'aime
8 Nice !
9 Top comme toujours
10 Les articles reçus il reste deux jours sont périmés
11 On m'a livré du coca qui allait expirer Quelques jours après livraison Et il avait mauvais goût !
12 انا افضل هذا الحجم على الحجم الكبير
13 J'aime bien
14 Le rendre sans sucre et dans aspartame.
15 It's is coca cola What wrong gonna happen anyway
16 شكرًا جوميا
17 Merci coca
18 ??????????????????????????????????
19 Bon produit
20 "Livraison rapide, mais mal emballé (pas de carton rien uniquement du scotch partout) et erreur de livraison par
21 تم توصيل في الوقت المناسب
22 zwina zero source
23 واعرا بزاف
24 Date hors périmé la honte
25 Top comme toujours
26 Bonne offre
27 Bvvvefvft
28 Merci jumia
29 Top livraison rapide
30 زوينة ولكن لي كييعانني من غازات المضرaran بلما يشربها فيها بزاف غازات
31 Super gazeuse wa3ra
32 J'aime bien

```

Figure 21 - résultat 1

data4.csv

```

122 Superbe
123 تقبيلة و زوينة و اقتصادية
124 رجعوا البرومو ليتّع، كانت، غالباً دبا
125 Très Bon produit
126 منافقها رائع جداً
127 Je préfère la 11
128 العشق الابدي
129 التاريخ قريب من الانتهاء لديه سطوك قديم .تاريخ الانتهاء شهر 9
130 "Bon café, prix et goût"
131 مروغيير مقبول
132 Bonne qualité et goût
133 رجعوا لبرومو ليتّع كانت دبا فليتوها بزاف
134 Frais et date de péremption loin
135 Bien !!!!
136 الحب والعشق، رجعوا لبرومو ليتّع كانت وشكرا
137 Livraison rapide
138 ""
139 LUNGO PROFONDO C LA MEILLEUR
140 I recommend this product
141 Bon produit
142 مزيان.....
143 très bon prix
144 Merci jumia
145 Bien !!!
146 Qualité top
147 Ta7ia Ljumia
148 parfait

```

Figure 22 - résultat 2

	data4.csv
309	Super expérience sur le shop Nivea
310	رائحة رائعة أحببته
311	Très bien
312	J'ai aimé le gel douche
313	رائع جدا
314	Zwiin w ri7a fih zwina ms l7ajm sghir
315	""
316	رائع و أهلي
317	Livraison Rapide et bien emballé
318	Excellent
319	Rapidement
320	كيرطب الجسم و رائحة روعة
321	Très bon service
322	J'aime
323	Bon odeur
324	Jaime normally
325	Bon produit
326	جيد جدا
327	Déodorant de qualité
328	"Très bonne qualité , redoo lbal st3mlaha 3la l7em mashi fou9 7waij 7it fiha poudre"
329	il est fort et il laisse des tache blanche
330	Bon pdt
331	Le moitié de la bouteille est vide
332	مكتبي قائم 48 ساعة غير شي 5 السو اربع
333	مسنارة
334	Ri7tha zwina. Jrebtha 3ajbat hta nas asdi9a dyali
335	Produit normal rien de spécial

Figure 23 - résultat 3

- Analyse des commentaires :

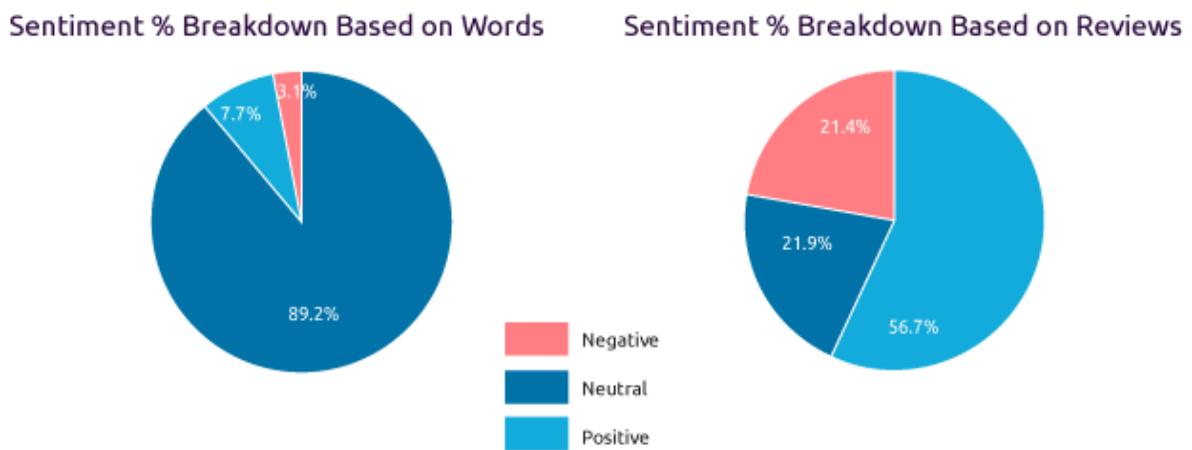


Figure 24 - résultat analyse

En se basant sur ces résultats, nous constatons que la plupart des commentaires sont positives.

Conclusion :

Dans ce chapitre, nous avons présenté les résultats du web scraping, ainsi d'analyse de texte.

Conclusion :

Sur le fond de notre projet, nous avons vu tout au long du rapport les étapes qui commençaient par un contexte général, le traitement des données, la mise en œuvre du projet et enfin les résultats obtenus.

Ce projet a ses racines dans le domaine du e-commerce, et son application serait utile pour les sociétés afin de savoir l'avis des clients et par la suite améliorer leurs produits, ainsi les comparer par rapport aux produits des concurrents. Ce projet a également été l'occasion d'améliorer et de développer nos compétences dans le domaine de programmation avec python.

Au long de ce projet, nous avons rencontré des nouvelles notions tels sentiments analysis et machine learning. Nos perspectives sont maintenant est de bien étudier des deux notions et s'approfondir afin de pouvoir travailler d'autre projets dans le futur.

Réalisé par :



EL MESKINI Rania

Rania.elmeskini37@gmail.com



ELAOUDI Oussama

Oussamaelaoudi49@gmail.co